利用虚拟机搭建Hadoop完全分布式集群

大致流程

- 虚拟机操作软件选择VMware Fusion
- 虚拟机选择Centos 7, 官网下载, 认准x86架构



CentOS-7-x86_64-DVD-2003.iso

- 因为集群需要多台虚拟机, 先配好一台, 然后克隆
 - 配置网络,多台虚拟机ip不同
 - 配置host,与ip——对应
 - 安装rsync,编写xsync集群部署脚本
 - 安装Java和Hadoop,并配置环境变量,官网下载,Hadoop认准Hadoop2.7.X, Java就 1.8,版本选择别整事
- 集群多台机器需要启动的服务不同,我用了三台虚拟机(配置不行要我高低我整10台),两主 一从,启动的服务一会说

虚拟机Nat模式网络配置

• 虚拟机的终端贼他妈不好使,可以用mac本地终端ssh一下

物理机端配置

- 确保虚拟机处于Nat模式下(Nat模式与物理机处于同一网段,二者同级)
- 修改物理机下面目录下的networking文件,VNET1是"仅主机模式的配置",我们修改 VNET8,修改后配置如下

/Library/Preferences/VMware Fusion

```
VERSION=1,0
answer VNET_1_DHCP yes
answer VNET_1_DHCP_CFG_HASH C5B4532FF80A53EDC9C36664BD44DE276E70AFC4
answer VNET_1_HOSTONLY_NETMASK 255.255.255.0
answer VNET_1_HOSTONLY_SUBNET 192.168.161.0
answer VNET_1_VIRTUAL_ADAPTER yes
answer VNET_3_DHCP no
answer VNET_3_NAT no
answer VNET_3_VIRTUAL_ADAPTER no
answer VNET_8_DHCP yes
answer VNET_8_DHCP_CFG_HASH 9BCFEB3491D0FB72F0158B1898587E22C37E8963
answer VNET_8_HOSTONLY_NETMASK 255.255.255.0
answer VNET_8_HOSTONLY_SUBNET 192.168.194.0
answer VNET_8_NAT yes
answer VNET_8_VIRTUAL_ADAPTER yes
add_bridge_mapping en0 2
```

 然后进入vnet8目录下,查看dchpd和nat.conf两文件,其中nat.conf里的ip和natmask是一会 我们虚拟机配置里的gateway和netmask,虚拟机ipaddr需要在dchpd网段range范围内(网 上说在设置-网络-TCP/IP里路由器同一网段是错的)

```
[(base) madi:vmnet8/ $ cat nat.conf
# VMware NAT configuration file
# Manual editing of this file is not recommended. Using UI is preferred.
[host]
# NAT gateway address
ip = 192.168.161.2
netmask = 255.255.255.0
```

• 修改完配置重启网络

```
sudo ifconfig en0 down
sudo ifconfig en0 up
```

- 查看DNS,设置-网络-高级-DNS,如有多个,写成DNS1=XXX,DNS2=XXX
- 修改完配置ping一下网络,看看物理机有没有被玩坏

• 进入/etc/sysconfig/network-scripts目录,修改ifcfg-ens33

B00TPR0T0 = static

ONBOOT = yes

IPADDR = 物理机dchp文件的range段里

NETMASK = 物理机NETMASK (一般是255.255.255.0)

GATEWAY = 物理机nat.conf文件里的ip

DNS = 设置里的DNS值

• 修改完重启网络

systemctl network restart

- 如果ping不通试着重启VMware和虚拟机
- 名字修改,修改/etc/hosts,IP对应端口号

127.0.0.1 localhost localhost.localdomain localhost4 localhost4.localdomain4 ::1 localhost localhost.localdomain localhost6 localhost6.localdomain6

192.168.194.131 hadoop101

192.168.194.132 hadoop102

192.168.194.133 hadoop103

网络配置详细博客

CentOS7配置网卡为静态IP,如果你还学不会那真的没有办法了!_牧马人-CSDN博客_centos7 网卡配置及静态ip配置 原创

防火墙相关

查看防火墙状态: firewall-cmd --state

关闭防火墙: systemctl stop firewalld.service

禁止防火墙开机启动: systemctl disable firewalld.service

查看服务列表: systemctl list-unit-files

xsync相关

- 是一个集群文件分发脚本
- 文件传输可用scp, 但是很麻烦, 集群内文件目录相同, 就没必要一个一个写
- 可分发多个集群, sheel里的while循环

xysnc配置

• 先下载包

yum -y install rsync # xsync是基于rsync的, rsync是远程同步工具, xsync是脚本

- 配置集群里各主机的/etc/hosts,让ip和主机名——对应,不对应也可以,在xsync脚本中把主机名改成ip地址就行,麻烦点
- 确保主机间可以ssh的情况下,编写脚本并执行

```
#!/bin/bash
#1 获取输入参数个数,如果没有参数,直接退出
pcount=$#
if((pcount==0)); then
echo no args;
exit;
fi
#2 获取文件名称
p1=$1
fname=`basename $p1`
echo fname=$fname
#3 获取上级目录到绝对路径 -P指向实际物理地址, 防止软连接
pdir=`cd -P $(dirname $p1); pwd`
echo pdir=$pdir
#4 获取当前用户名称
user=`whoami`
```

JAVA相关

• 下载Java,java应该是一个具体的版本,选择开发版,可以先yum search看一下 yum –y install java

配置环境变量

```
vi /etc/profile
export JAVA_HOME=/usr/lib/jvm/java-1.8.0-openjdk-1.8.0.262.b10-0.el7_8.x86_64

export CLASSPATH=.:$JAVA_HOME/jre/lib/rt.jar:$JAVA_HOME/lib/dt.jar:$JAVA_HOME/
lib/tools.jar

export PATH=$PATH:$JAVA_HOME/bin

export HADOOP_HOME=/root/hadoop-2.7.2
export PATH=$PATH:$HADOOP_HOME/bin

# 具体配置看情况,别忘记激活,完事echo $JAVA_HOME看一下
source /etc/profile
```

Hadoop相关

- 下载Hadoop,官网找,可以调出Hadoop的配置文件的文档,写的比CSDN上那帮2B好多了
- 解压,放在自己的目录下,这个目录就是环境变量
- 配置环境变量 /etc/profile

```
export HAD00P_HOME=/root/hadoop-2.7.2
export PATH=$PATH:$HAD00P_HOME/bin
```

- # 路径根据自己需要调整
- # 公司级的服务器有严格的目录标准,我图省事放root下了

集群配置

- 需要配置四个东西HDFS, YARN, Mapreduce, Core (核心文件), Slaves文件
- core-site.xml,其中namenode地址、tmp文件夹位置按需选择
 - tmp文件夹的作用是保存mapreduce的中间操作生成的临时文件
 - 当mapreduce完成时,临时文件被删除
 - 劝你选个好找的

HDFS

- HDFS有两个文件需要修改, hadoop-env.sh和hdfs-site.xml
- 为什么叫hadoop-env我也不知道,可能因为HDFS是Hadoop的灵魂吧,我猜的

```
# hadoop-env.sh
export JAVA_HOME=$JAVA_HOME
# 所有涉及env的都是修改JAVA_HOME
# 注意,文件的注释里有了,解开就行
```

```
# hdfs-site.xml <!-- 指定Hadoop辅助名称节点主机配置 -->
```

YARN

```
<name>yarn.secondarynamenode.hostname</name>
   <value>hadoop102</value>
</property>
<!-- 指定YARN的DataNode的地址 -->
roperty>
   <name>yarn.datanode.hostname
   <value>hadoop103</value>
</property>
<!-- 日志聚集功能使能 -->
property>
   <name>yarn.log-aggregation-enable
   <value>true</value>
<!-- 日志保留时间设置7天 -->
cproperty>
   <name>yarn.log-aggregation.retain-seconds
   <value>604800</value>
</property>
```

MapReduce

克隆的虚拟机配置修改

• IP, 去/etc/sysconfig/network-scripts目录,修改ifcfg-ens33,把IPADDR改了,不同节点不一样,最好跟名字对应,改完重启网络

systemctl restart network

• 如果没有在克隆之前完成Java和Hadoop的配置也没关系,利用集群分发脚本

rsync -rvl /root /root

- # 第一个路径是你配好环境的root目录,第二个是其他节点的目录,按需选择
- # 具体看xsync脚本, 里面的IP和host都可控
- Slaves文件
 - 在hadoop家目录下/etc/hadoop/slaves
 - 加入你所有的节点名字,注意不要有空格空行
 - 为什么不能空,我也不知道,我看的博客说了,别惹事还是加上
- 以上任何文件如果是克隆前修改的都可以通过xsync发到其他节点,过程需要一个一个输密码,实际可以改成公私钥的形式,免除密码

集群启动

振奋人心的时刻

• 我的集群

• Hadoop101 (主节点): 启动了ResourceManager, NodeManager, NameNode

• Hadoop102 (备份主): 启动了SecondaryNameNode, NodeManager

• Hadoop103(从节点):启动了DataNode, NodeManager

• 启动文件都在HADOOP_HOME的sbin下

第一次启动需要格式化NameNode

hdfs namenode -format

- # 主节点启动YARN和NameNode
- # YARN包括了RM和NM

NameNode和ResourceManger如果不是同一台机器,不能在NameNode上启动 YARN,应该在ResouceManager所在的机器上启动YARN

集群测试

• 浏览器访问集群管理UI界面

HDFS: hadoop101:50070YARN: hadoop101:8088

• 具体情况看集群启动服务的情况

• 利用命令在HDFS上创建文件夹,上传文件夹

hadoop fs -mkdir /Test
hadoop fs -put /root/test.txt /Test

- 执行mapreduce demo
 - # 先上传一个wordcount.txt文件
 - # 然后执行mapreduce脚本
 - # 在/root/hadoop-2.7.2/share/hadoop/mapreduce下

hadoop jar hadoop-mapreduce-examples-2.7.2.jar wordcount /Test/wordcount.txt / Test/Output

- # 第一个路径是测试文件在HDFS的路径,第二个为输出结果路径
- # 第二个路径必须是不存在的, 否则报错